

Fundamentos de aprendizado de máquina baseados em algoritmos quânticos

Daniel Coutinho - IC - Licenciatura em Física - Petrópolis

Felipe de Almeida - IC - Licenciatura em Matemática - Petrópolis

Demerson Nunes - Professor - Departamento de Matemática - Petrópolis

Joao Dias - Professor - Coordenação de Telecomunicações - Maracanã

Centro Federal de Educação Tecnológica do Rio de Janeiro - Cefet/RJ

September 23, 2025

Agenda

Aula 1:

- Fundamentos de aprendizado de máquina;
- Evolução do aprendizado de máquina;
- Motivação para usar aprendizado de máquina;
- Inferência Indutiva;
- Conjunto de dados;
- Aprendizados supervisionado, semi e não supervisionados, por reforço e ativo;
- Generalização;
- Viés indutivo;
- Aplicações de Aprendizado de máquina.
- SVM para classificação e regressão.

Agenda

Aula 2:

- Supremacia quântica;
- Origem da computação quântica
- Aplicações da computação quântica
- Principais algoritmos quânticos
- As regras do jogo

Agenda

Aula 3:

- Demonstração experimental de uso do computador quântico da IBM;
- Implementação experimental de circuitos de portas quânticas no computador quântico da IBM;

Aula 4:

- Vantagens da computação quântica em relação a computação clássica;
- Aplicação de algoritmos quânticos em sistemas de comunicações;
- Comparação da complexidade computacional dos algoritmos;
- Análise de desempenho dos sistemas de comunicações baseados em algoritmos.

Aula 1: Fundamentos de aprendizado de máquina

- Imagine escrever um programa de computador que:

- Reconheça pessoas pelo rosto

- Problemas:

- Diferentes expressões faciais
- Alterações na face (ex. óculos, bigode)
- Cortes de cabelo
- Etc.

Que características considerar??



Seres humanos: reconhecimento de padrões,
aprendizado do que deve ser observado após vários exemplos

Fundamentos de aprendizado de máquina

- Necessidade de ferramentas mais **autônomas**
 - Reduzindo necessidade de intervenção humana e dependência de especialistas

Aprendizado de Máquina: técnicas capazes de criar, a partir de experiência passada, uma hipótese (função) capaz de resolver o problema

- Ex: regra definida por análise de prontuários médicos

Se temperatura $> 37^{\circ}\text{C}$ e tem dores então está doente



Evolução do aprendizado de máquinas

1950s

1960s


1970s

1980s

1990s

2000s

- 1952: programa jogador de **damas** de Samuel
- 1959: modelo **Pandemonium** de Selfridge
 - Reconhecimento de padrões
 - Padrão é reconhecido em partes antes do total
 - Aprendizado por meio de ajustes de pesos



Evolução do aprendizado de máquinas

1950s

1960s


1970s

1980s

1990s

2000s


- **Redes Neurais:** Perceptron (1957), Adaline (1960)
- 1969: Minsky e Papert provam limitações do Perceptron



Evolução do aprendizado de máquinas

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- Indução simbólica de conceitos
- Sistemas especialistas e o gargalo de aquisição de conhecimento
- Algoritmo ID3 (*Iterative Dichotomiser 3*) de Quinlan



Evolução do aprendizado de máquinas

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- Aprendizado de Regras
- EBL (*Explanation-based Learning*)
- Ressurgimento das Redes Neurais (*backpropagation* - 1986)
- Teoria de Aprendizado PAC (*Probably Approximately Correct*)
 - Estrutura para análise matemática de AM
- Foco em metodologia de experimentos



Evolução do aprendizado de máquinas

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- Sistemas Inteligentes Híbridos
- Mineração de Dados (1996) e de Textos
- Agentes de software adaptativos e aplicações na web
- Aprendizado por Reforço
- ILP (*Inductive Logic Programming*)
- *Ensembles: Bagging, Boosting e Stacking*
- Aprendizado por redes bayesianas
- Computação Bioinspirada



Evolução do aprendizado de máquinas

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Máquinas de Vetores de Suporte (*Support Vector Machines*)
- Modelos Gráficos
- Aplicações mais diversas
- Redes neurais profundas (*deep learning*)



Motivação para usar aprendizado de máquinas

- Automatizar o processo de aquisição de conhecimento
- Entender melhor os mecanismos de aprendizado humano
- Algumas tarefas são melhor definidas e/ou executadas a partir de exemplos
 - Ex.: Reconhecer pessoas
- Ser humano não é capaz de explicar (e programar) sua habilidade para executar alguns tipos de tarefas
 - Ex.: Dirigir



Motivação para usar aprendizado de máquinas

- **Quantidade de conhecimento** disponível pode ser muito grande para ser descrito (e programado) por humanos
 - Ex.: diagnóstico médico
- Algumas tarefas exigem **cálculos complexos**, possíveis apenas com computador
 - Ex.: interrelacionar/correlacionar grandes quantidades de dados
- Modelos de AM podem se **adaptar a novas situações**
Evita necessidade de reprogramação



O que é aprendizado

- Essencial para comportamento inteligente
- Algumas atividades:
 - Memorizar algo
 - Observar e explorar situações para aprender fatos
 - Melhorar habilidades motoras/cognitivas por prática
 - Organizar conhecimento novo em representações apropriadas



Definição de aprendizado de máquina


Um programa **aprende** a partir da experiência **E**, em relação a uma classe de tarefas **T**, com medida de desempenho **P**, se seu desempenho em **T**, medido por **P**, melhora com **E**

Mitchell, 1997

Capacidade de melhorar o desempenho na realização de alguma tarefa por meio da experiência

Exemplo de aprendizado de máquina

- **Problema:** aprender a **jogar** damas
 - Tarefa T: jogar damas
 - Medida de desempenho P: porcentagem de jogos vencidos contra adversários ou contra si próprio
 - Experiência E: praticar jogando



Arthur Lee Samuel
(criou o termo "*machine learning*" em 1959):
programa de jogar damas,
primeiro programa com auto-aprendizado.
Jogou milhares de vezes conta si mesmo
Chegou a nível amador

Exemplo de aprendizado de máquina

- **Problema:** **filtrar** mensagens de email
 - Tarefa T: categorizar mensagens de email como spam ou legítima
 - Medida de desempenho P: porcentagem de mensagens de spam e legítimas corretamente identificadas
 - Pode ter um peso diferente para cada erro
 - Experiência E: conjunto de e-mails apontados pelo usuário como spams



Exemplo de aprendizado de máquina

- **Problema:** reconhecer escrita manual
 - Tarefa T: reconhecer e classificar dígitos manuscritos dentro de imagens
 - Medida de desempenho P: porcentagem de dígitos corretamente identificados
 - Experiência E: imagens de dígitos manuscritos por diferentes pessoas

MNIST database:

images of handwritten digits, collected among Census Bureau employees and high-school students. Writers of the training set and test set are disjoint.

USPS database:


numeric data obtained from the scanning of handwritten digits from envelopes by the U.S. Postal Service

Exemplo de aprendizado de máquina

Problema: carro autônomo (aprender a **dirigir**)

Tarefa T: *dirigir em uma rodovia pública usando sensores*

- **Medida de desempenho P:** distância média percorrida antes de um erro
- **Experiência E:** sequência de imagens e comandos de direção registrados observando um motorista humano




Exemplo de aprendizado de máquina

- **Problema:** detectar bons clientes
 - **Tarefa T:** classificar potenciais clientes como bons ou maus pagadores
 - **Medida de desempenho P:** porcentagem de clientes classificados corretamente como bons e maus pagadores
 - **Experiência E:** uma base de dados histórica com dados de clientes já conhecidos



Inferência Indutiva

- A **Inferência Indutiva** é um dos principais meios para a aquisição de novos conhecimentos
- **Indução**: raciocínio para obter conclusões sobre todos os membros de uma classe pelo exame de alguns membros da classe



Raciocínio do particular para o geral

Exemplo de Inferência indutiva

- Se eu noto que:
 - Todos pacientes com déficit de atenção atendidos em 1986 sofriam de ansiedade
 - Todos pacientes com déficit de atenção atendidos em 1987 sofriam de ansiedade
 - ...
 - **⇒ Posso inferir que pacientes que sofrem de déficit de atenção também sofrem de ansiedade**

Isto pode ser ou não verdade,
mas propicia uma boa **generalização**

Conjunto de dados

- Experiência pode ser provida por um conjunto de dados (de treinamento)
 - Ex. base de dados de um hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Meta: induzir hipótese para fazer diagnósticos corretos para novos pacientes

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada **linha** (paciente) é um **dado**
(objeto, exemplo, padrão ou registro)

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada objeto é uma tupla com valores de **características** (atributos, campos ou variáveis), que descrevem seus principais aspectos

Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Atributo de saída (alvo/meta): presente em algumas tarefas, seus valores devem ser estimados usando outros atributos (de entrada/preditivos)

Importante: atributos de identificação e nome não possuem relação com a doença e não são utilizados como entradas


Conjunto de dados

- Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	?	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	7	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M		Uniformes	38,4	2	GO	Saudável

Importante: lidar com dados imperfeitos (ruídos, ausentes, etc.)

Área multidisciplinar



Tarefas de aprendizado

- Divisão geral: **Preditivas** vs **Descritivas**

Previsão

Encontrar função (modelo ou hipótese) que possa ser utilizada para prever um rótulo ou valor para novos dados


Objetos na forma
(entrada, saída)

Descrição

Explorar ou descrever um conjunto de dados

Objetos não possuem saída associada

Hierarquia de aprendizado



Importante: divisão não é rígida (modelo preditivo também provê descrição dos dados e modelo descritivo pode prover previsões após validado)
E existem outras formas de realizar o aprendizado preditivo/descritivo

Aprendizado supervisionado

- Supervisor externo
 - Conhece **saída desejada** para cada exemplo
 - Representado por conjunto de pares (x, y)
 - Ex.: x = sintomas e y = diagnóstico

Classificação

Rótulos discretos

Ex.: diagnóstico, bom/mau pagador, etc.



Regressão

Rótulos contínuos


Ex.: peso, altura, etc.

Aprendizado supervisionado

Classificação



Regressão



Aprendizado não supervisionado

- Algoritmos não fazem uso de atributo de saída
 - Exploram regularidades nos dados

Sumarização

Encontrar descrição compacta para dados

Associação


Encontrar padrões frequentes de associações entre atributos

Agrupamento

Dados agrupados de acordo com sua similaridade

Hierarquia de aprendizado

Hierarquia clássica



Aprendizado por reforço

- Reforçar/recompensar ações positivas e punir ações negativas
 - Crítico externo


Aprendizado supervisionado

- Supervisor
- É dito o que fazer
- Mais rápido

Aprendizado por reforço

- Crítico
- Faz e vê o que acontece
- Mais lento

Aprendizado semi-supervisionado




Aprendizado semi-supervisionado

- **Classificação/regressão**: usa dados rotulados e não rotulados
 - Dados não rotulados são mais frequentes
 - Rotular dados é custoso
- **Agrupamento**: usa conhecimento de que exemplos devem estar no mesmo grupo ou não


Aprendizado semi-supervisionado

Dados rotulados

Fronteira de decisão



Fronteira de decisão mais acurada na presença de exemplos não rotulados




Dados não rotulados

<https://www.analyticsvidhya.com/blog/2017/09/pseudo-labelling-semi-supervised-learning-technique/>

Aprendizado ativo

- Identifica que exemplos não rotulados são distintos dos já conhecidos e então solicita o rótulo deles
 - Uso de um “oráculo”



Generalização

- Capacidade de **generalização** de uma hipótese:
 - Propriedade de continuar válida para outros objetos que não fazem parte de seu conjunto de treinamento

Problemas:

Overfitting: especialização nos dados de treinamento, não generaliza

Underfitting: baixo acerto mesmo nos dados de treinamento


Viés indutivo

- **Aprendizado:** busca de hipótese em espaço de possíveis hipóteses
 - Que descreva relacionamentos entre os dados
 - E se ajuste aos dados de treinamento
- Todo algoritmo de AM indutivo tem um **viés**
 - Na escolha de uma hipótese (ou conjunto)

Sem viés, não haveria generalização (modelos seriam especializados para os exemplos individuais)

Viés indutivo

- Viés de **representação ou linguagem**
 - Define o espaço de busca
 - Restringe hipóteses que podem ser geradas



0.45	-0.40	0.54	0.12	0.98	0.37
-0.45	0.11	0.91	0.34	-0.20	0.83
-0.29	0.32	-0.25	-0.51	0.41	0.70

Redes neurais

Se Peso ≥ 50 **então** Doente
Se Peso < 50 **e** Sexo = M **então** Doente
Se Peso < 50 **e** Sexo = F **então** Saudável

Conjunto de regras

Viés indutivo

- Viés de **preferência ou busca**
 - Como hipóteses são pesquisadas
 - Preferência de algumas hipóteses sobre outras
 - Ex.: preferência por hipóteses curtas
 - Navalha de Occam

"Se em tudo o mais forem idênticas as várias explicações de um fenômeno, a mais simples é a melhor"

Aplicações clássicas de aprendizado de máquina

Número crescente de aplicações

Finanças: análise de risco, detecção de fraudes, gerenciamento de carteiras

Internet: algoritmos de busca, marketing na web

Ciência e Medicina: descoberta de padrões, diagnóstico de pacientes, análise de dados do genoma

Indústrias: previsão de falhas, diagnóstico de produtos

Marketing: segmentação de mercado, recomendação de produtos

Telecomunicações: processamento de alarmes e sensores

Muito usada em Mineração de Dados, *Big Data*, *Analytics*, Ciência de Dados, ...

Support vector machine (SVM) - para classificação




Figure: From: Analytics Vidhya.

- Seja $\{(x_j, y_j)\}_{j=1}^L$ um conjunto de dados linearmente separável.
- SVM encontra o hiperplano ótimo com parâmetros (w, b) que divide as duas classes e maximiza o limite das regiões de decisão $\frac{1}{\|w\|}$.
- A função de decisão é dada por

$$f(x) = \text{sign}(\langle w^*, x \rangle + b^*). \quad (1)$$

- Os valores ideais w^* e b^* vêm do procedimento de otimização.

Non-linear SVM




Figure: From: Analytics Vidhya.

O método do kernel

- **Etapas 1:** Aplique o mapa de características ϕ à expressão (1) para obter $f(\mathbf{x}) = \text{sign}(\langle \mathbf{w}, \phi(\mathbf{x}) \rangle + b)$.
- **Etapas 2:** Use o Teorema do Representador (Kimeldorf Wahba, 1971) para reescrever $\mathbf{w}$ como uma combinação linear dos pontos de dados incorporados de treinamento: $\mathbf{w} = \sum_{j=1}^L \alpha_j y_j \phi(\mathbf{x}_j)$.
- **Etapas 3:** Assim, a equação (1) torna-se


$$f(\mathbf{x}) = \text{sign} \left(\sum_{j=1}^L \alpha_j y_j \langle \phi(\mathbf{x}_j), \phi(\mathbf{x}) \rangle + b \right). \quad (2)$$

- A função $K(\mathbf{x}_j, \mathbf{x}) = \langle \phi(\mathbf{x}_j), \phi(\mathbf{x}) \rangle$ é chamada de *kernel*.

Support vector machine (SVM) - para regressão

Modelo: $f(x) = \langle w, \phi(x) \rangle + b$

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*), \text{ subject to } \begin{cases} y_i - \langle w, \phi(x_i) \rangle - b \leq \varepsilon + \xi_i \\ \langle w, \phi(x_i) \rangle + b - y_i \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases}$$



Processo de otimização

A lagrangiana é dada por

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + C \sum_i (\xi_i + \xi_i^*) - \sum_i (\eta_i \xi_i + \eta_i^* \xi_i^*) - \sum_i \alpha_i (\varepsilon + \xi_i - y_i + \langle w, \phi(x_i) \rangle + b) - \sum_i \alpha_i^* (\varepsilon + \xi_i^* + y_i - \langle w, \phi(x_i) \rangle - b)$$

Com isso, temos: $\frac{\partial \mathcal{L}}{\partial w} = 0$, $\frac{\partial \mathcal{L}}{\partial b} = 0$, $\frac{\partial \mathcal{L}}{\partial \xi_i} = 0$ e $\frac{\partial \mathcal{L}}{\partial \xi_i^*} = 0$

De onde

$$w = \sum_i (\alpha_i - \alpha_i^*) \phi(x_i) \text{ e } \boxed{f(x) = \sum_i (\alpha_i - \alpha_i^*) \langle \phi(x_i), \phi(x) \rangle + b}$$

Kernel: $k(x, y) = \langle \phi(x), \phi(y) \rangle$

Aula 2: Agenda

- Visal geral sobre a CQ
- Propriedades da MQ
- Leis da MQ
- Circuitos e Algoritmos Quânticos

Por que estudar Computação Quântica?




Figure: Lov Grover

Busca numa lista não-estruturada.

6	2	0	9	1	7	4	4	8	5	3
---	---	---	---	---	---	---	---	---	---	---



The unsorted list of numbers!

- Clássico: $O(N)$ operações
- Quântico (1996): $O(\sqrt{N})$ operações

Por que estudar Computação Quântica?





Figure: Peter Shor

Fatoração de inteiros em tempo polinomial!



- Segurança/Criptografia
- Quântico: $O(\log N)$

O que é Computação Quântica?

É um novo modelo computacional baseado na Mecânica Quântica que promete resolver problemas complexos de forma mais eficiente que os computadores clássicos.




Figure: CQ Google - 53 qubits (2019)


Daniel C., Felipe A., Demerson G. e Joao D.



Figure: "CQ" Jiuzhang - 76 qubits (2020)

Quando surgiu a CQ?


A natureza é quântica! Existem problemas que são impossíveis serem resolvidos em computadores clássicos.



(Richard Feynman, 1985)
" Let's build computers based in quantum mechanical elements, which obey quantum mechanical laws!"

Modelos computacionais

- Bits clássicos: **escalares**
- Implementação: **circuitos elétricos**
- Baseada na **lógica booleana**



- Bits quânticos: **vetores**
- Implementação: **sistema de fótons, elétrons, etc**
- Baseada na **Mecânica Quântica**




Qubit - quantum bit

Qubit é a unidade de informação quântica. Tem papel equivalente ao bit no computador clássico.

● 0


● 1

Classical Bit




Qubit


Como criar um qubit?



SPIN DO ELÉTRON




Estado quântico do elétron




- Estado antes da medida: $|\Psi\rangle = \alpha|\uparrow\rangle + \beta|\downarrow\rangle$
- Estado após a medida: $|\uparrow\rangle$ com prob. $|\alpha|^2$ ou $|\downarrow\rangle$ com prob. $|\beta|^2$

Emaranhamento (ou entrelaçamento) quântico



- No emaranhamento, dois qubits interagem com polarizações opostas.
- Uma modificação em qualquer dos qubits afeta instantaneamente o outro.

Interferência




Vantagens

- Qubits são sensíveis à Interferência e colapsam quando ocorre algum distúrbio.
- Impossibilidade de cópias. Isso é bom para criptografia.

Desvantagens

- Decoerência quântica - decaimento quântico
- Geração de erros.

Computação Quântica x Clássica



J. Preskill (Caltech, 2017):
Supremacia quântica consiste em demonstrar que um dispositivo quântico programável pode resolver um problema que nenhum computador clássico pode resolver em tempo viável;

Computadores Quânticos




Figure: CQ Google - 53 qubits (2019)







Figure: "CQ" Jiuzhang - 76 qubits (2020)

Sycamore - Processador do CQ do Google (2019)

- Sycamore, foi capaz de executar em 200 segundos uma operação para calcular números aleatórios que o computador clássico mais poderoso da atualidade levaria 10 mil anos.
- [1] F. Arute,..., John M. Martinis. Quantum supremacy using a programmable superconducting processor. Nature, vol. 574, 2019.




Sycamore - Processador do CQ do Google (2019)



Daniel C., Felipe A., Demerson G. e Joao D.

Jiuzhang - Computador Quântico Chinês (2020)

- Problema da amostragem de bosons (proposto por Aaronson et al - 2010).
- Implementação não programável de um circuito óptico com 76 ftons, 300 beam splitters, 75 espelhos.



Jiuzhang - Computador Quântico Chinês (2020)

- A amostragem de bósons substitui as bolinhas por fótons, e os pinos por espelhos e prismas.
- Os fótons são disparados através da matriz e pousam em um “slot” no final, onde detectores registram sua presença.
- Devido às propriedades quânticas, um dispositivo com apenas 50 fótons poderia produzir tantas distribuições que computadores clássicos levariam bilhões de anos para prevê-las.





Figure: "Experimento de Galton"


Existem outros CQ?

Universal Gate Based Quantum Computers			Annealing
Superconducting Architecture			Quantum Annealing
			
Trapped Ions	Topological	Photonic	
			

E não para por aí... (IBM Roadmap)



IBM Quantum Experience - Composer



Como funciona a Computação Quântica?

- 1 Como representar uma unidade de informação num sistema físico?
- 2 Como representar sistemas compostos?
- 3 Como manipular a informação?
- 4 Como ler a informação do sistema físico?

Leis da MQ - as regras do jogo!

- 1 O estado de um sistema físico isolado é uma superposição de possíveis estados (vetores) deste sistema.
- 2 A evolução do sistema é descrita pela aplicação de um operador unitário ao vetor que descreve o estado do sistema.
- 3 Uma medição colapsa a superposição para uma única possibilidade clássica.
- 4 O estado de sistemas compostos é obtido via produto das partes.

Postulado 1 - Representação de um qubit

O qubit é representado por um vetor unitário em $\mathbb{C}^2$

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle$$

Onde


$$|\alpha|^2 + |\beta|^2 = 1.$$

Os estados $|0\rangle$ e $|1\rangle$ são descritos por

$$|0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad |1\rangle = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

Logo,

$$|\psi\rangle = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$$



Notação de Dirac

- $v \rightarrow |v\rangle$

- Base:

$$\{v_0, v_1, \dots, v_{n-1}\} \rightarrow \{|v_0\rangle, |v_1\rangle, |v_n\rangle\} \rightarrow \{|0\rangle, |1\rangle, \dots, |n-1\rangle\}$$

- **Importante:** Vetor $|0\rangle \neq$ vetor nulo.

- Vetor com n entradas: $|v\rangle = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}$

- Vetor dual: $\langle v| = [a_1^*, a_2^*, \dots, a_n^*]$

Produtos interno e externo

- Produto interno: $\langle s | s \rangle = \sum_{i=1}^n a_i^* a_i$

- Base ortonormal: $\langle s | s \rangle = \delta_{ij}$

- Produto externo:

$$|s\rangle \langle s| = \begin{bmatrix} a_1 a_1^* & \dots & a_1 a_n^* \\ & \ddots & \\ a_n a_1^* & \dots & a_n a_n^* \end{bmatrix}$$

Postulado 4 - Sistema com múltiplos qubits

O espaço de estados de um sistema composto é o produto tensorial dos espaços dos estados dos componentes. Se $|\psi_1\rangle, |\psi_2\rangle, \dots, |\psi_n\rangle$ descrevem os estados de n sistemas quânticos isoladamente, então o estado do sistema composto é

$$|\psi_1\rangle \otimes |\psi_2\rangle \otimes \dots \otimes |\psi_n\rangle$$

Produto Tensorial - Estado de dois qubits

- Estados de 1 qubit da base computacional

$$|1\rangle \otimes |0\rangle = |10\rangle = |2\rangle$$

- Para estados genéricos $|\psi_1\rangle = \alpha |0\rangle + \beta |1\rangle$ e $|\psi_2\rangle = \alpha' |0\rangle + \beta' |1\rangle$ temos

$$\begin{aligned} |\psi_1\rangle \otimes |\psi_2\rangle &= (\alpha |0\rangle + \beta |1\rangle)(\alpha' |0\rangle + \beta' |1\rangle) \\ &= \alpha\alpha' |0\rangle + \alpha\beta' |1\rangle + \beta\alpha' |2\rangle + \beta\beta' |3\rangle \end{aligned}$$

Base computacional - 2 qubits

$$|0\rangle = |00\rangle = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$|1\rangle = |01\rangle = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

$$|2\rangle = |10\rangle = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

$$|3\rangle = |11\rangle = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

Base computacional - n qubits

$$|0\rangle = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad |1\rangle = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad \dots \quad |N-1\rangle = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

Onde $N = 2^n$, n é o número de qubits.

Postulado 2 - Evolução unitária

A evolução de um sistema quântico fechado é descrita por uma transformação unitária.

$$|\psi'\rangle = U|\psi\rangle$$

Um operador U num espaço complexo de dimensão finita é dito **unitário** se

$$UU^\dagger = U^\dagger U = I.$$

Exemplos de operadores unitários para 1 qubit:

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \quad Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Evolução unitária

Exemplo: Seja $|\psi\rangle = \alpha |0\rangle + \beta |1\rangle$, calcule

$$|\psi'\rangle = U |\psi\rangle$$


para cada uma das matrizes unitárias abaixo:

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \quad Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Evolução unitária

- $I |\psi\rangle = |\psi\rangle = \alpha |0\rangle + \beta |1\rangle$
- $H |\psi\rangle = \frac{\alpha+\beta}{\sqrt{2}} |0\rangle + \frac{\alpha-\beta}{\sqrt{2}} |1\rangle$
- $X |\psi\rangle = \beta |0\rangle + \alpha |1\rangle$
- $Y |\psi\rangle = -i\beta |0\rangle + i\alpha |1\rangle$
- $Z |\psi\rangle = \alpha |0\rangle - \beta |1\rangle$

Porta CNOT - 2 qubits



Paralelismo Quântico

- Sistema quântico com n qubits:

$$|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle$$

- Ao se aplicar um operador unitário U , ele é aplicado a todos os estados simultaneamente.

$$\begin{aligned} |\psi'\rangle &= U(\alpha_0 |0\rangle + \alpha_1 |1\rangle + \dots + \alpha_{2^n-1} |2^n - 1\rangle) \\ &= U\alpha_0 |0\rangle + U\alpha_1 |1\rangle + \dots + U\alpha_{2^n-1} |2^n - 1\rangle \end{aligned}$$

Qubits x Bits

Devido a essa propriedade da superposição de estados, enquanto com o uso dos Bits, as possibilidades são somadas, no caso dos Qubits as possibilidades de estados são multiplicadas.

1 qubit = 2 bits	8 qubits = 256 bits
2 qubits = 4 bits	9 qubits = 512 bits
3 qubits = 8 bits	10 qubits = 1.024 bits
4 qubits = 16 bits	15 qubits = 32.768 bits
5 qubits = 32 bits	20 qubits = 1.048.576 bits
6 qubits = 64 bits	30 qubits = 107.373.568 bits
7 qubits = 128 bits	40 qubits = 109.950.533.633 bits

Tabela: Comparação Qubits x Bits

Como extrair informação do estado quântico?

- Para retirar uma informação de uma sequência de n bits, basta olharmos para os seus valores. Essa operação de leitura de um bit não traz consigo nenhuma complicação, visto que a mesma não altera em nada o estado do bit lido.
- No entanto, essa estratégia de leitura em uma superposição de n Qubits não funciona! Só há uma forma de extrair informação de um Qubit e essa ação é chamada de “tomar uma medida” (em inglês, “making a measurement”).
- A medida consiste em realizar testes em cada Qubit onde o resultado é sempre o valor 0 ou 1. Tais resultados não são determinados pela função de estado $|\Psi\rangle$ da superposição, visto que a função de estado só nos disponibiliza a probabilidade de recebermos um resultado particular.

Medida Quântica - Postulado 3

Dado um estado de superposição de n qubits

$$|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle$$

temos que a probabilidade de um resultado i_0 ser obtido é dada por:

$$p(i_0) = |\alpha_{i_0}|^2$$


O estado após a medida fica

$$\frac{|i_0\rangle}{\sqrt{p(i_0)}}.$$

Esta operação é irreversível, ou seja, a partir de $\frac{|i_0\rangle}{\sqrt{p(i_0)}}$ não é possível recuperar o estado original $|\psi\rangle$.


Medida em termos de circuitos

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$$



- $prob(0) = |\alpha|^2$
- $prob(1) = |\beta|^2$


entrada: $|\psi\rangle = |0\rangle$



- $prob(0) = 0,5$
- $prob(1) = 0,5$


$$\text{saída: } |\psi'\rangle = \frac{1}{\sqrt{2}}|0\rangle + \frac{1}{\sqrt{2}}|1\rangle$$

Modelo padrão da computação quântica




- A porta U deve satisfazer $UU^\dagger = I$
- Realize uma medição na base computacional
- Obtenha o estado $|i\rangle$ com probabilidade $|\alpha_i|^2$

Criando emaranhamento



- Após uma operação de medida, o resultado é
 - $|00\rangle$ com probabilidade $\frac{1}{2}$
 - $|11\rangle$ com probabilidade $\frac{1}{2}$

Circuito quântico para somar bits




Principais Referências

- [1] M.A. Nielsen and I.L. Chuang. Quantum Computation and Quantum Information, *Contemporary Physics - CONTEMP PHYS*, 2011.
- [2] P. Rebentrost, M. Mohseni and S. Lloyd, *Quantum Support Vector Machine for Big Data Classification*, Vol -14, pp. 3-8, American Physical Society, 2014.
- [3] V. Bergholm et al., *PennyLane: Automatic differentiation of hybrid quantum-classical computations.*, arXiv:1811.04968 (2018).

Algoritmos Quânticos - IBM Quantum Composer

- Login



Google

ibm quantum computing

Todas Notícias Imagens Vídeos Shopping Mais Ferramentas

Aproximadamente 15.200.000 resultados (0,60 segundos)

Dica: Pesquisar apenas resultados em **português (Brasil)**. Especifique seu idioma de pesquisa em Preferências

Artigos acadêmicos sobre **ibm quantum computing**

- Quantum** artificial life in an **IBM quantum computer** - Alvarez-Rodriguez - Citado por 88
- Quantum computing** for finance: State-of-the-art and ... - Egger - Citado por 94
- Quantum computing**: An **IBM** perspective - Steffen - Citado por 59


 <https://www.ibm.com/quantum> Traduzir esta página

IBM Quantum Computing

IBM Quantum leads the world in **quantum computing**. This nascent technology is widely expected to solve valuable problems that today's most powerful classical ...

IBM · Quantum · Quantum systems · IBM Quantum Tools

Algoritmos Quânticos - IBM Quantum Composer



The screenshot shows the IBM Quantum website. The top navigation bar includes the IBM logo, the word "Quantum", and several menu items: "Products", "Access Plans", "Technology", "Solutions", "Docs", "Learn", and "Community". On the right side of the navigation bar is a link that says "Launch IBM Quantum". A large red arrow points directly at this link. Below the navigation bar is a large video player. The video has a black background with white text on the left that reads "Introducing our new 2022 development roadmap". On the right side of the video is a portrait of Jay Gambetta, a man with short brown hair wearing a dark blue shirt. Below his name, it says "Vice President, IBM". At the bottom left of the video frame, there is a paragraph of text: "Plans for 4 new quantum processors, breakthrough technologies and leaps forward in scale, quality and speed. Jay Gambetta and team take us on a journey to 2025 and the era of the quantum-centric supercomputer."

IBM | Quantum | Products ▾ | Access Plans | Technology ▾ | Solutions ▾ | Docs ▾ | Learn ▾ | Community ▾ | [Launch IBM Quantum](#)

Introducing our new 2022 development roadmap

Plans for 4 new quantum processors, breakthrough technologies and leaps forward in scale, quality and speed. Jay Gambetta and team take us on a journey to 2025 and the era of the quantum-centric supercomputer.

Jay Gambetta
Vice President, IBM

Algoritmos Quânticos - IBM Quantum Composer

IBM Quantum

Real quantum computers. Right at your fingertips.

IBM offers cloud access to the most advanced quantum computers available.
Learn, develop, and run programs with our quantum applications and systems.

Learn quantum computing

Sign in to IBM Quantum

IBMid

G Q in [social icons]

New to IBM Quantum?
[Create an IBMid account.](#)

Algoritmos Quânticos - IBM Quantum Composer

IBM

Efetue login na IBM

IBMid

[Esqueceu o IBMid?](#)

☐ Recordar-se de mim ⓘ

Continuar →

Não tem uma conta? [Crie um IBMid](#)

Precisa de ajuda? [Entre em contato com o help desk do IBMid](#)



Algoritmos Quânticos - IBM Quantum Composer



Criar sua conta IBM

Acesso a testes, demonstrações, kits, serviços e API

Já tem uma conta IBM? [Efetuar login](#)

Criar uma conta IBM GRÁTIS

1. Informações de conta

Entrar com o LinkedIn

Preencher suas informações automaticamente

Email ⓘ

Seu endereço de e-mail se tornará seu IBMid, que você usará para efetuar login no IBM.com.


Primeiro nome

Sobrenome

Senha (Password)



Algoritmos Quânticos - IBM Quantum Composer



The screenshot shows the IBM Quantum Composer interface. At the top, there is a dark header with the IBM Quantum logo on the left and search, help, and user icons on the right. The main content area has a light gray background. It begins with the text "Last step! Before you get started," followed by the heading "Tell us a little more about yourself". Below this, there are four form fields: "First name *" with the value "Daniel", "Last name *" with the value "Coutinho", "Your institution *" with the placeholder "Enter your institution", and "What is your familiarity with quantum?" with a dropdown menu showing "Select an option". The final field is "What would you like to use IBM Quantum for?" with an empty text input area.

IBM Quantum

Last step! Before you get started,

Tell us a little more about yourself

First name *

Daniel

Last name *

Coutinho

Your institution *

Enter your institution

What is your familiarity with quantum?

Select an option

What would you like to use IBM Quantum for?

Algoritmos Quânticos - IBM Quantum Composer

IBM Quantum

Welcome, Daniel Coutinho

Graphically build circuits with
IBM Quantum Composer

Develop quantum experiments in
IBM Quantum Lab

Get started locally @
Your API token

View account details

Recent notifications [View all](#)

- Service Alert
Maintenance event on September 8th
13 days ago
- Quantum News
Interested in helping us build the future of
quantum? Take part in the IBM Quantum
Feedback Program.
19 days ago | [Learn more](#)
- Product Update
Updates to job executions - optimizing
classical computation
about 2 months ago
- Service Alert
ibmq_armonk has been retired
2 months ago


Relembrando...

- Base computacional: $|0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ $|1\rangle = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$
- Portas lógicas: $X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ $Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}$ $Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

$$R_x(\theta) = \begin{bmatrix} \cos\left(\frac{\theta}{2}\right) & -i\sin\left(\frac{\theta}{2}\right) \\ -i\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \quad R_y(\theta) = \begin{bmatrix} \cos\left(\frac{\theta}{2}\right) & -\sin\left(\frac{\theta}{2}\right) \\ \sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix}$$

$$R_z(\theta) = \begin{bmatrix} e^{-i\theta/2} & 0 \\ 0 & e^{i\theta/2} \end{bmatrix} \quad H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

Primeiros passos...



$$|0\rangle \xrightarrow{X} |1\rangle$$

$$X|0\rangle = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} = |1\rangle$$

$$|0\rangle \xrightarrow{Y} e^{i\frac{\pi}{2}} |1\rangle$$

$$Y|0\rangle = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ i \end{bmatrix} = i|1\rangle = e^{i\frac{\pi}{2}} |1\rangle$$

$$e^{i\theta} = \cos(\theta) + i\sin(\theta)$$

$$|0\rangle \text{ --- } \boxed{Z} \text{ --- } |0\rangle$$

$$Z|0\rangle = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = |0\rangle$$

$$|0\rangle \text{ --- } \boxed{I} \text{ --- } |0\rangle$$

$$I|0\rangle = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = |0\rangle$$

$$|1\rangle \xrightarrow{Z} e^{i\pi} |1\rangle$$

$$Z|1\rangle = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \end{bmatrix} = -|1\rangle = e^{i\pi} |1\rangle$$

$$|0\rangle \xrightarrow{H} \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$$

$$H|0\rangle = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$$

$$H|0\rangle = |+\rangle \text{ e } H|1\rangle = |-\rangle$$



$$|0\rangle \xrightarrow{R_x(\pi)} e^{i\frac{3\pi}{2}} |1\rangle$$

$$R_x(\pi) = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -i\sin\left(\frac{\pi}{2}\right) \\ -i\sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -i \\ -i & 0 \end{bmatrix} = -i \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = e^{i\frac{3\pi}{2}} X$$

$$R_x(\pi) |0\rangle = e^{i\frac{3\pi}{2}} X |0\rangle = e^{i\frac{3\pi}{2}} |1\rangle$$

$$R_x(0) = R_y(0) = R_z(0) = I$$

Inversas e Medição...




$$P_1 = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

$$P_1 \left[\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \right] = \frac{1}{\sqrt{2}} \left(\begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} |1\rangle$$

Algoritmo de Deutsch

Objetivo: determinar se a função binária f é constante ($f(0) = f(1)$) ou balanceada ($f(0) \neq f(1)$).



$$U_f(|x\rangle |-\rangle) = (-1)^{f(x)} |x\rangle |-\rangle$$

$$1) |\psi_1\rangle = (H \otimes H)(|0\rangle \otimes |1\rangle) = H|0\rangle \otimes H|1\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \otimes |-\rangle$$

$$|\psi_1\rangle = \frac{1}{\sqrt{2}}(|0\rangle |-\rangle + |1\rangle |-\rangle)$$

$$2) |\psi_2\rangle = U_f \left[\frac{1}{\sqrt{2}}(|0\rangle |-\rangle + |1\rangle |-\rangle) \right] = \frac{1}{\sqrt{2}}(U_f |0\rangle |-\rangle + U_f |1\rangle |-\rangle)$$

$$|\psi_2\rangle = \frac{1}{\sqrt{2}}[(-1)^{f(0)} |0\rangle |-\rangle + (-1)^{f(1)} |1\rangle |-\rangle]$$

$$|\psi_2\rangle = \frac{1}{\sqrt{2}}[(-1)^{f(0)} |0\rangle + (-1)^{f(1)} |1\rangle] \otimes |-\rangle$$

$$3) |\psi_3\rangle = (H \otimes I) \left(\frac{1}{\sqrt{2}} [(-1)^{f(0)} |0\rangle + (-1)^{f(1)} |1\rangle] \otimes |-\rangle \right)$$

$$|\psi_3\rangle = \frac{1}{\sqrt{2}} [(-1)^{f(0)} H |0\rangle + (-1)^{f(1)} H |1\rangle] \otimes I |-\rangle$$

$$|\psi_3\rangle = \frac{1}{2} [(-1)^{f(0)} (|0\rangle + |1\rangle) + (-1)^{f(1)} (|0\rangle - |1\rangle)] \otimes I |-\rangle$$

$$|\psi_3\rangle = \frac{1}{2} [(-1)^{f(0)} |0\rangle + (-1)^{f(0)} |1\rangle + (-1)^{f(1)} |0\rangle - (-1)^{f(1)} |1\rangle] \otimes |-\rangle$$

$$|\psi_3\rangle = \frac{1}{2} [(-1)^{f(0)} + (-1)^{f(1)}] |0\rangle + \frac{1}{2} [(-1)^{f(0)} - (-1)^{f(1)}] |1\rangle \otimes |-\rangle$$


Lembrando que $P(0) = |\alpha|^2$ e $P(1) = |\beta|^2$ quando $|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$.

$$P(0) = \frac{1}{4}|(-1)^{f(0)} + (-1)^{f(1)}|^2$$

Se medirmos 0 no primeiro registrador com $P(0) = 1$, então $f(0) = f(1)$, ou seja, f é constante.

Classicamente, teríamos que fazer $f(0)$ e $f(1)$ (duas operações) para saber se f é constante ou balanceada.

Cadeado Quântico



acesso negado: $output = 0$
acesso concedido: $output = 1$
senha errada: $|0\rangle$
senha correta: $|1\rangle$

Lembrando que $Z|0\rangle = |0\rangle$ e $Z|1\rangle = -|1\rangle$.

- Vamos testar a senha $|0\rangle$.

$$1) (H \otimes I) (|0\rangle \otimes |0\rangle) = H|0\rangle \otimes I|0\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \otimes |0\rangle$$

$$\begin{aligned} 2) CZ_{1,2} \left[\frac{1}{\sqrt{2}}(|0\rangle|0\rangle + |1\rangle|0\rangle) \right] &= \frac{1}{\sqrt{2}}(CZ_{1,2}|0\rangle|0\rangle + CZ_{1,2}|1\rangle|0\rangle) \\ &= \frac{1}{\sqrt{2}}(|0\rangle|0\rangle + |1\rangle|0\rangle) = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \otimes |0\rangle \end{aligned}$$

$$3) (H \otimes I) \left(\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \otimes |0\rangle \right) = H \left(\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \right) \otimes I|0\rangle = \underline{|0\rangle|1\rangle}$$

Ao medir o 1º qubit, temos $output = 0$.

- Vamos testar a senha $|1\rangle$.


$$1) (H \otimes I) (|0\rangle \otimes |1\rangle) = H|0\rangle \otimes I|1\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle) \otimes |1\rangle$$

$$\begin{aligned} 2) CZ_{1,2} \left[\frac{1}{\sqrt{2}}(|0\rangle|1\rangle + |1\rangle|1\rangle) \right] &= \frac{1}{\sqrt{2}}(CZ_{1,2}|0\rangle|1\rangle + CZ_{1,2}|1\rangle|1\rangle) \\ &= \frac{1}{\sqrt{2}}(|0\rangle|1\rangle - |1\rangle|1\rangle) = \frac{1}{\sqrt{2}}(|0\rangle - |1\rangle) \otimes |1\rangle \end{aligned}$$


$$3) (H \otimes I) \left(\frac{1}{\sqrt{2}}(|0\rangle - |1\rangle) \otimes |1\rangle \right) = H \left(\frac{1}{\sqrt{2}}(|0\rangle - |1\rangle) \right) \otimes I|1\rangle = \underline{|1\rangle|1\rangle}$$

Ao medir o 1º qubit, temos *output* = 1.

Teletransporte Quântico



- Um exemplo com $|\psi\rangle = |1\rangle$.



$$|\psi_1\rangle = \frac{1}{2} (|0\rangle |0\rangle |1\rangle + |0\rangle |1\rangle |0\rangle - |1\rangle |0\rangle |1\rangle - |1\rangle |1\rangle |0\rangle)$$

- Existem quatro possibilidades de outputs após a medição dos dois primeiros qubits.

- $|0\rangle |0\rangle$
- $|0\rangle |1\rangle$
- $|1\rangle |0\rangle$
- $|1\rangle |1\rangle$

Consideremos que o resultado após a medição dos dois primeiros qubits seja $|0\rangle |1\rangle$. Com isso, $|\Psi_2\rangle = |0\rangle |1\rangle |0\rangle$.

$$CZ_{1,3} CNOT_{2,3} |0\rangle |1\rangle |0\rangle = CZ_{1,3} |0\rangle |1\rangle |1\rangle = |0\rangle |1\rangle |1\rangle$$

O terceiro qubit está no estado inicial do primeiro qubit!

Problema de Rotação

- Considere o seguinte algoritmo quântico: $|0\rangle \xrightarrow{R_x(\pi)} \xrightarrow{R_y(\theta)} |\psi\rangle$

Determine $\theta \in [0, \frac{\pi}{2}]$ sabendo que $\langle\psi| Z |\psi\rangle = -\frac{1}{2}$.

$$|\psi\rangle = R_y(\theta)R_x(\pi)|0\rangle = R_y(\theta)(-iX)|0\rangle = -iR_y(\theta)X|0\rangle = -iR_y(\theta)|1\rangle$$

$$|\psi\rangle = -iR_y(\theta)|1\rangle \text{ e } \langle\psi| = \langle 1| R_y^\dagger(\theta)i$$

$$|\psi\rangle = -iR_y(\theta)|1\rangle = -i \begin{bmatrix} \cos\left(\frac{\theta}{2}\right) & -\sin\left(\frac{\theta}{2}\right) \\ \sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = -i \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) \\ \cos\left(\frac{\theta}{2}\right) \end{bmatrix}$$

$$\langle\psi| = \langle 1| R_y^\dagger(\theta)i = \begin{bmatrix} 0 & 1 \end{bmatrix} \begin{bmatrix} \cos\left(\frac{\theta}{2}\right) & \sin\left(\frac{\theta}{2}\right) \\ -\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} i$$

$$\langle\psi| = i \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix}$$

$$\langle \psi | Z | \psi \rangle = i \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} (-i) \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) \\ \cos\left(\frac{\theta}{2}\right) \end{bmatrix}$$

$$\langle \psi | Z | \psi \rangle = \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) \\ \cos\left(\frac{\theta}{2}\right) \end{bmatrix}$$

$$\langle \psi | Z | \psi \rangle = \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) & \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \begin{bmatrix} -\sin\left(\frac{\theta}{2}\right) \\ -\cos\left(\frac{\theta}{2}\right) \end{bmatrix} = \sin^2\left(\frac{\theta}{2}\right) - \cos^2\left(\frac{\theta}{2}\right)$$

Lembrando que $-\cos(\theta) = \sin^2\left(\frac{\theta}{2}\right) - \cos^2\left(\frac{\theta}{2}\right)$.

$$-\cos(\theta) = \langle \psi | Z | \psi \rangle$$

$$-\cos(\theta) = -\frac{1}{2}$$

$$\theta = \frac{\pi}{3} \text{rad}$$


Aula 4: Uma Introdução a SVM - Support Vector Machines - e o aprendizado quântico

- Historia das SVMs;
- Duas classes, linearmente separáveis;
- O que é um bom limite para a decisão?
- Duas classes, não linearmente separáveis;
- Como lidar com não linearidades: kernel
- Exemplos de SVM;
- SVM quântico.

Historia das SVMs



- SVM é um classificador derivado da teoria de aprendizado estatístico por Vapnik e Chervonenkis;
- SVM se tornou famosa quando, usando mapas de pixels como entrada, ela teve acurácia comparável a uma sofisticada rede neural com características elaboradas na tarefa de reconhecimento de escrita;
- Atualmente, as pesquisas em SVM esta relacionada a: Métodos de Kernel, classificadores de máxima margens (large margin classifiers), reprodução de espaços de kernel Hilbert, processos Gaussianos;

Duas classes, linearmente separáveis;




- Diferentes limites de decisão podem separar estas duas classes;
- Qual devemos escolher?

Exemplos



Bons limites de decisão: As Margens devem ser máximizadas



$$m = \frac{2}{||w||}$$

Bons limites de decisão: As Margens devem ser máximizadas

- Sendo as retas de suporte:

$$\begin{aligned}w^T x + b = 1 &\rightarrow w^T x + b - 1 = 0 \Rightarrow s : w^T x + 0y + (b - 1); \\w^T x + b = -1 &\rightarrow w^T x + b + 1 = 0 \Rightarrow t : w^T x + 0y + (b + 1).\end{aligned}$$

Logo, a distância entre essas duas retas paralelas será:

$$m = \frac{|(b - 1) - (b + 1)|}{\sqrt{(w^T)^2 + 0^2}} = \frac{|-2|}{\sqrt{(w^T)^2}} = \frac{2}{\|w\|}$$

O problema de otimização

- Seja $x_1, \dots, x_n$ um conjunto de dados e seja $y_i \in \{1, -1\}$ a classe da instância x_i . O limite de decisão deve classificar todos os pontos corretamente, ou seja, $y_i(w^T x_i + b) \geq 1, \forall i$
- O problema de otimização é

$$\begin{aligned} & \text{Minimize } \frac{1}{2} \|w\|^2 \\ & \text{sujeito a } y(w^T x_i + b) \geq 1 \quad \forall i \end{aligned}$$

Transformação no problema dual

- O problema pode ser transformado no seu dual

$$\begin{aligned} \text{Max } W(\alpha) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{sujeito a } \alpha_i &\geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

- Isto é um problema quadrático (QP), os máximos globais de α_i podem ser sempre encontrados e $\mathbf{w}$ podem ser calculado como

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

Características das Soluções

- Muitos α_i são zeros
 - $\mathbf{w}$ é uma combinação linear de um pequeno numero de dados;
 - Representação esparsa.
- $\mathbf{x}_i$ com não-zero α_i são chamados vetores de suporte (SV). Seja $t_j (j = 1, \dots, s)$ os índices dos s vetores de suporte


$$\mathbf{w} = \sum_{j=1}^s \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$$

- Para um novo dato $\mathbf{z}$. Calcule

$$\mathbf{w}^T \mathbf{z} + b = \sum_{j=1}^s \alpha_{t_j} y_{t_j} (\mathbf{x}_{t_j}^T \mathbf{z}) + b$$

e classifique $\mathbf{z}$ como classe 1 se a soma for positiva.

Uma interpretação Geométrica




Alguma observações

- Existem limites teóricos sobre o erro em dados não vistos pela SVM
 - Maior margem, menor o limite
 - Menor número de SV, menor o limite
- Note que ambos treinamento e teste, os dados são somente referenciados por seu produto interno, $\mathbf{x}^T \mathbf{y}$
 - Isto é importante para generalizar o caso não linear

E quando não existe separação linear

- Se permite um erro de classificação ξ_i



Hyperplano de margem suave

- Defina $\xi_i = 0$ se não existe erro para x_i
 - $\xi_i = 0$ são somente “variáveis de folga” na otimização

$$\begin{aligned}w^T x_i + b &\geq 1 - \xi_i & y_i &= 1 \\w^T x_i + b &\leq -1 + \xi_i & y_i &= -1 \\ \xi_i &\geq 0 & \forall i\end{aligned}$$

- minimizar $\frac{1}{2}||\mathbf{w}'||^2 + C \sum_{i=1}^n \xi_i$
 - C :parametro de balance entre o erro e a margem
- Assim o problema de otimização é

$$\begin{aligned}& \text{Minimize } \frac{1}{2}||w||^2 + C \sum_{i=1}^n \xi_i \\& \text{sujeito a } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0\end{aligned}$$

O problema de otimização

- O problema dual é

$$\text{Max } W(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{sujeito a } C \geq \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$


- $\mathbf{w}$ é calculado com $\mathbf{w} = \sum_{j=1}^s \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$
- A única diferença é que existe um limite superior C em α_i
- De novo, um QP pode ser usado para encontrar α_i

Extensão a limites de decisão não lineares

- Ideia Chave: transformar $\mathbf{x}_i$ a um espaço de maior dimensão
 - Espaço de Entrada: o espaço $\mathbf{x}_i$
 - Espaço de características: o espaço de $\phi(\mathbf{x}_i)$ após a transformação
- Porque transformar?
 - Operações lineares no espaço de características é equivalente a operações não lineares no espaço de entrada
 - A tarefa de classificação pode ser mais fácil com a transformação apropriada.

Extensão a limites de decisão não lineares

- Problemas possíveis da transformação
 - Difíceis de calcular e de obter uma boa estimativa
- SVM resolve estes dois problemas simultaneamente
- As funções Kernel não precisam ser calculados



Truque do kernel

- O produto interno pode ser calculado por K sem necessidade de realizar o mapeamento $\phi(\cdot)$
- As relações entre a função de Kernel K e o mapeamento $\phi(\cdot)$ é $K(\mathbf{x}, \mathbf{y}) = \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle$
 - Isto é conhecido pelo nome de truque de Kernel
- Na pratica, pode-se especificar $\phi(\cdot)$ indiretamente, ao invés de escolher $\phi(\cdot)$
- Intuitivamente, $K(\mathbf{x}, \mathbf{y})$ representa nosso desejo de noção de similaridade entre $\mathbf{x}$ e $\mathbf{y}$ e isto forma nosso conhecimento a priori
- $K(\mathbf{x}, \mathbf{y})$ precisa satisfazer a condição Mercer para que $\phi(\cdot)$ exista
- Pesquisa em diferentes funções de kernel é muito ativa

Modificações devido a função de kernel

- Mude todos os produtos internos pela função de kernel
- Para treinamento
 - Original

$$\text{Max } W(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{sujeito a } C \geq \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

- Com kernel

$$\text{Max } W(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{sujeito a } C \geq \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

Modificações devido a função de kernel

- Para testar, o novo dado z é classificado como classe 1 se $f \geq 0$, e classe 2 se $f \leq 0$
- Original

$$\mathbf{w} = \sum_{j=1}^s \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$$

$$f = \mathbf{w}^T \mathbf{z} + b = \sum_{j=1}^s \alpha_{t_j} y_{t_j} (\mathbf{x}_{t_j}^T \mathbf{z}) + b$$

- Com kernel

$$\mathbf{w} = \sum_{j=1}^s \alpha_{t_j} y_{t_j} \phi(\mathbf{x}_{t_j})$$

$$f = \mathbf{w}^T \mathbf{z} + b = \sum_{j=1}^s \alpha_{t_j} y_{t_j} K(\mathbf{x}_{t_j}, \mathbf{z}) + b$$

Exemplo

- Suponha que temos 5 dados $1D$
 - $x_1 = 1, x_2 = 2, x_3 = 4, x_4 = 5, x_5 = 6$, com 1, 2, 6 da classe 1 e 4, 5 da classe 2
 $\Rightarrow y_1 = 1, y_2 = 1, y_3 = -1, y_4 = -1, y_5 = 1$.
- A função de kernel polinomial de grau 2
 - $K(x, y) = (xy + 1)^2$
 - $C = 100$
- Primeiro encontra-se $\alpha_i (i = 1, \dots, 5)$ como

$$\text{Max} \sum_{i=1}^5 \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^5 \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \mathbf{x}_j + 1)^2$$
$$\text{sujeito a } 100 \geq \alpha_i \geq 0, \sum_{i=1}^5 \alpha_i y_i = 0$$


Exemplo

- Usando um QP solver, obtém se
 - $\alpha_1 = 0, \alpha_2 = 2.5, \alpha_3 = 0, \alpha_4 = 7.333, \alpha_5 = 4.833$
 - Note que as restrições são satisfeitas
 - Os vetores de suporte são $x_2 = 2, x_4 = 5, x_5 = 6$
- A função discriminante é

$$\begin{aligned} f(y) &= 2.5(1)(2y + 1)^2 + 7.333(-1)(5y + 1)^2 + 4.833(1)(6y + 1)^2 + b \\ &= 0.6667x^2 - 5.333x + b \end{aligned}$$

- b é recuperado por $f(2) = 1$ ou $f(5) = -1$ ou $f(6) = 1$, como x_2, x_4, x_5 está em $y_i(w^T \phi(z) + b) = 1$, $b = 9$. Então, $f(y) = 0.6667x^2 - 5.333x + 9$

Exemplo



Classificação multi-classe

- SVM é basicamente um classificador binário
- Pode mudar-se a formulação QP para permitir classificação multi-classe
- Comumente, os dados são divididos em duas partes em diferentes maneiras e são treinadas diferentes SVM uma para cada divisão
- Classificação Multi-classe é realizada combinando a saída de todas as SVM
 - Regra da maioria
 - Código de correção do erro
 - Gráfico acíclico direto

Resumo: Passos para a classificação

- Prepare o padrão de entrada
- Selecione a função de kernel
- Selecione o parâmetro da função de kernel e o valor de C
- Execute o algoritmo de treinamento e obtenha α_i
- Os novos dados podem ser classificados usando α_i e os vetores de suporte

Conclusão

- SVM é uma alternativa a redes neurais
- Dois conceitos da SVM: maximize a margem e o truque de kernel
- Diferentes áreas de pesquisa ativas
- Muitas implementações de SVM estão disponíveis

Espaços Euclidianos

- **Espaço euclidiano** é um espaço vetorial real de dimensão finita com produto interno.
- Seja V um espaço vetorial euclidiano. A **norma (ou comprimento)** de um elemento $v \in V$, denotada por $\|v\|$, é definida por $\|v\| = \sqrt{\langle v, v \rangle}$
- A **distância (ou métrica)** entre dois elementos $u, v \in V$, denotada por $d(u, v)$, é definida por: $d(u, v) = \|u - v\|$.
- Um espaço vetorial com norma é denominado **espaço normado** e um espaço vetorial com distância é denominado **espaço métrico**.

Espaços Euclidianos

Norma e Distância Euclidiana em $\mathbb{R}^n$: Considere o espaço vetorial $\mathbb{R}^n$ com produto interno. Sejam $u = (u_1, u_2, \dots, u_n)$ e $v = (v_1, v_2, \dots, v_n)$ vetores do $\mathbb{R}^n$. Então, a norma com relação ao produto interno Euclidiano, denotada por $\|\cdot\|_2$ e definida por:

$$\|v\|_2 = \sqrt{\langle v, v \rangle} = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2}$$


é denominada norma euclidiana do $\mathbb{R}^n$. Além disso, a distância com relação a norma euclidiana, definida por:

$$d(u, v) = \|u - v\|_2 = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2 + \dots + (u_n - v_n)^2}$$

é denominada **distância euclidiana** do $\mathbb{R}^n$.

Espaços de Hilbert

Sequência de Cauchy: é uma sucessão de pontos tal que a distância entre os termos vai se aproximando de zero.




Espaços de Hilbert

- **Espaço completo** é um espaço métrico onde todas as sucessões de Cauchy convergem para um limite que pertence ao espaço.
- Seja H um espaço vetorial sobre um corpo K (Reais ou Complexos) e $\langle ., . \rangle : H \rightarrow K$ um produto interno, então H é um espaço de Hilbert se for completo com a norma induzida pelo produto interno, isto é:


$$\|x\| = \sqrt{\langle x, x \rangle}$$

- $\mathbb{C}^n$ com produto interno $\langle x, y \rangle = x_1^* y_1 + \dots + x_n^* y_n$ é um espaço de Hilbert.


K-nearest neighbours (KNN) clássico



Distância entre estados quânticos - Teste Swap




Passo 1 - Porta Hadamard



$$\frac{|0\rangle + |1\rangle}{\sqrt{2}} |a\rangle |b\rangle = \frac{1}{\sqrt{2}} (|0\rangle |a\rangle |b\rangle + |1\rangle |a\rangle |b\rangle)$$

$|0\rangle |a\rangle |b\rangle$
↓


Passo 2 - Porta Swap Controlada



$$\begin{aligned} & |0\rangle |a\rangle |b\rangle \\ & \downarrow \\ & \frac{|0\rangle + |1\rangle}{\sqrt{2}} |a\rangle |b\rangle = \frac{1}{\sqrt{2}} (|0\rangle |a\rangle |b\rangle + |1\rangle |a\rangle |b\rangle) \\ & \downarrow \\ & \frac{1}{\sqrt{2}} (|0\rangle |a\rangle |b\rangle + |1\rangle |b\rangle |a\rangle) \end{aligned}$$

The diagram illustrates the state transformation during the controlled swap operation. The initial state is $|0\rangle |a\rangle |b\rangle$. This is transformed into a superposition $\frac{|0\rangle + |1\rangle}{\sqrt{2}} |a\rangle |b\rangle$. The state $|1\rangle$ in the superposition is highlighted with an orange box, and a blue curved arrow indicates the swap of $|a\rangle$ and $|b\rangle$ in the second term. The final state is $\frac{1}{\sqrt{2}} (|0\rangle |a\rangle |b\rangle + |1\rangle |b\rangle |a\rangle)$, where the state $|1\rangle$ is again highlighted with an orange box.

Passo 3 - Aplique Hadamard novamente



Passo 4 - Medir o primeiro registrador

$$|\psi\rangle = \frac{1}{2} [(|0\rangle + |1\rangle) |a\rangle |b\rangle + (|0\rangle - |1\rangle) |b\rangle |a\rangle] = \frac{1}{2} [|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + |1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)]$$

If $|a\rangle = |b\rangle$

$$|\psi\rangle = \frac{1}{2} [|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + |1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)]$$

- Note que se $|a\rangle = |b\rangle$, uma medida no primeiro registrador resulta em $|0\rangle$ com prob. 100%.

Qual a prob. de medir o primeiro qubit?

$$|\psi\rangle = \frac{1}{2} [|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + |1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)]$$

$$\begin{aligned} P(|0\rangle_c) &= |\langle 0|\psi\rangle|^2 = \left| \frac{1}{2} [\langle 0|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + \langle 0|1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)] \right|^2 \\ &= \left| \frac{1}{2} [(|a\rangle |b\rangle + |b\rangle |a\rangle)] \right|^2 = \frac{1}{4} (\langle a|\langle b| + \langle b|\langle a|)(|a\rangle |b\rangle + |b\rangle |a\rangle) \\ &= \frac{1}{4} (\langle a|a\rangle \langle b|b\rangle + \langle a|b\rangle \langle b|a\rangle + \langle b|a\rangle \langle a|b\rangle + \langle b|b\rangle \langle a|a\rangle) = \frac{1}{4} (2 + 2 \langle a|b\rangle \langle b|a\rangle) \\ &= \frac{1}{2} + \frac{1}{2} |\langle a|b\rangle|^2 \end{aligned}$$

Qual a prob. de medir o primeiro qubit?

$$|\psi\rangle = \frac{1}{2} [|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + |1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)]$$

$$P(|0\rangle) = \frac{1}{2} + \frac{1}{2} |\langle a|b\rangle|^2$$

$$P(|1\rangle) = \frac{1}{2} - \frac{1}{2} |\langle a|b\rangle|^2$$


	$ a\rangle = b\rangle$	$ a\rangle \perp b\rangle$
$P(0\rangle)$	1	1/2
$P(1\rangle)$	0	1/2

Cálculo do produto interno

$$|\psi\rangle = \frac{1}{2} [|0\rangle (|a\rangle |b\rangle + |b\rangle |a\rangle) + |1\rangle (|a\rangle |b\rangle - |b\rangle |a\rangle)]$$

$$P(|0\rangle) = \frac{1}{2} + \frac{1}{2} |\langle a|b\rangle|^2$$

$$P(|1\rangle) = \frac{1}{2} - \frac{1}{2} |\langle a|b\rangle|^2$$



$$|\langle a|b\rangle|^2 = 1 - 2P(|1\rangle) = 1 - 2 \left(\frac{1}{N} \sum_{i=1}^N M_i \right) \quad N \rightarrow \infty$$

Obrigado!